

MBA EM
DATA SCIENCE

Data Wrangling

Prof. Dr. Wilson Tarantin Junior

MBA **USP**
ESALQ

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98


Data Wrangling

- É o processo de transformar a base de dados de sua estrutura original (dados brutos) para uma nova estrutura mais adequada que permita a extração de informações
 - Raramente os dados brutos estão disponíveis na estrutura mais apropriada para as análises
 - Portanto, é uma etapa de **preparação, organização, manipulação** dos bancos de dados
 - Ocorre antes da análise exploratória dos dados, criação de gráficos e modelagem
 - Quanto melhor for a etapa de data wrangling, melhores serão os dados e maior tende a ser a qualidade da análise e das informações extraídas → **dados mais consistentes e confiáveis**
 - **Não é uma atividade padronizada! Dado o contexto, diferentes etapas são aplicadas**

Data Wrangling


- Atividades comuns no processo de tratamento dos dados
 - **Coleta e importação:** os dados podem ser provenientes de diversas fontes e em vários formatos. Exemplos: dados em XLSX, CSV ou Parquet provenientes de sites especializados, APIs, ERPs e CRMs (consultas SQL), entre outros
 - **Junção:** os dados provenientes das diferentes fontes precisam ser organizados para possibilitar a união de observações e variáveis. Exigem variáveis que sejam “chaves” para o relacionamento entre as tabelas
 - **Transformação:** contempla as etapas de modificação dos dados. Exemplos: limpeza dos dados, criação e alteração de variáveis, seleção de observações, agregações, resumos...

CRISP-DM (Cross-Industry Standard Process for Data Mining)



Fonte: https://commons.wikimedia.org/wiki/File:CRISP-DM_Process_Diagram.png

Data Wrangling



Fonte: <https://online.hbs.edu/blog/post/data-wrangling>

Python

- Biblioteca para data wrangling
- Embora muitas bibliotecas sejam úteis no processo de manipulação de dados, utilizaremos o **pandas** como ferramenta principal
 - Manual do usuário: https://pandas.pydata.org/docs/user_guide/index.html
 - Material de consulta: https://pandas.pydata.org/Pandas_Cheat_Sheet.pdf



Sugestões de Leituras/Referências

- CHEN, D. Pandas for Everyone: Python Data Analysis. Addison-Wesley Professional, 2017.
- FÁVERO, L. P.; BELFIORE, P. Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. LTC, 2024.
- GRUS, J. Data Science do zero: noções fundamentais com Python. 2 ed. Alta Books, 2021.
- HARRISON, M. Effective Pandas: Patterns for Data Manipulation. Treading on Python (Livro 2).
- McKINNEY, W. Python Para Análise de Dados: Tratamento de Dados com Pandas, NumPy & Jupyter. Novatec Editora, 2023.
- VANDERPLAS, J. Python Data Science Handbook: Essential Tools for Working with Data. 2 ed. O'Reilly Media, 2023.

Obrigado!

Wilson Tarantin Jr. | [linkedin.com/in/wilson-tarantin-junior-359476190](https://www.linkedin.com/in/wilson-tarantin-junior-359476190)

